

10 Das Gradientenverfahren

Ziel: Untersuchung von Bedingungen für die Richtungswahl. Einfaches Verfahren zur Lösung von (P) ist das **Gradientenverfahren**: $p^k := -\nabla f(x^k)$.

Offensichtlich gilt dann: $\nabla f(x^k)^T p^k = -\|\nabla f(x^k)\|^2 < 0$.

Das Gradientenverfahren mit semi-effizienter Schrittweitenregel lautet:

- Algorithmus 10.1**
- 1) Wähle eine semi-effiziente Schrittweitenregel und ein $x^0 \in \mathbb{R}^n$. Setze $k := 0$.
 - 2) Falls $\nabla f(x^k) = 0$: STOP! x^k ist kritische Lösung von Problem (P).
 - 3) Setze $p^k := -\nabla f(x^k)$.
 - 4) Bestimme eine Schrittweite $t_k > 0$ gemäß Schrittweitenregel und $x^{k+1} := x^k + t_k \cdot p^k$.
 - 5) Setze $k := k+1$ und gehe zu 1).

Im Fall von einer beliebigen semi-effizienten Schrittweitenregel sind mit $H_k := I$ und $m := M=1$ alle Voraussetzungen von Satz 8.17 erfüllt, so dass aus diesem Satz diese Konvergenzaussage folgt:

- Satz 10.2**
- Es gelten (U1)-(U3). Wenn Algorithmus 10.1 nicht nach endlich vielen Schritten ab, so erzeugt er eine unendliche Folge $(x^k)_k$ mit:
- i) Jeder Häufungspunkt von $(x^k)_k$ ist kritische Lösung von (P)
 - ii) Bezieht (P) genau eine kritische Lösung x^* in N_0 , so ist $\lim_{k \rightarrow \infty} x^k = x^*$.
 - iii) Ist auch (U4) erfüllt und x^* die dann existierende Lösung von (P), so folgt $\lim_{k \rightarrow \infty} x^k = x^*$ und mit der Semi-effizienzkonstante $\nu > 0$ aus der Schrittweitenregel und einem $c > 0$ gilt: $0 \leq f(x^{k+1}) - f(x^*) \leq (1 - 2\beta\nu^2) \cdot [f(x^k) - f(x^*)]$, $k \in \mathbb{N}_0$
sowie: $\|x^k - x^*\| \leq c \cdot (\sqrt{1 - 2\beta\nu^2})^k$, $k \in \mathbb{N}_0$

Das Gradientenverfahren konvergiert für jede Schrittweitenregel aus Kapitel 9 mit einer Teilfolge gegen eine kritische Lösung (wenn (U1)-(U3) erfüllt). Ist auch noch (U4) erfüllt, so konvergiert die gesamte Iteriertenfolge und zwar (mindestens) Q-linear sowie die Folge der Funktionswerte Q-linear.

Langsame Konvergenz kann nicht mehr ausgeschlossen werden, wenn $2\beta\nu^2$ sehr klein ist. Die Konstante ν hängt dabei von der jeweiligen Schrittweitenregel ab. Für die exakten Schrittweiten (Minimum-, Curry-Schrittweite) gilt nach Satz 5.3: $\nu^2 := \nu_k^2 = \nu^2 = \frac{1}{2\beta}$. Für die Schrittweiten kann langsame Konvergenz eintreten, falls $\frac{1}{\beta}$ klein ist.

Untersuche das Gradientenverfahren mit exakter Schrittweite für den Fall einer quadratischen Funktion $f(x) := \frac{1}{2}x^T Qx + c^T x + \kappa$, $x \in \mathbb{R}^n$ mit Q positiv definit und symmetrisch.

Dann hat (P) wegen $\nabla f(x^*) = 0 \Leftrightarrow Qx^* + c = 0$ die eindeutige Lösung $x^* := -Q^{-1} \cdot c$. Aus Beispiel 8.7 wissen wir, dass $\text{cond}(Q) = \frac{\lambda_{\max}(Q)}{\lambda_{\min}(Q)} = \frac{1}{\nu^2}$. Mit der Beziehung $\nu^2 = \frac{1}{\beta_k} = \frac{1}{\beta} = \frac{1}{2\beta}$ kann man schreiben: $1 - 2\beta\nu^2 = 1 - 2\beta \frac{1}{2\beta} = 1 - \frac{1}{\beta} = 1 - \frac{1}{\text{cond}(Q)} = \frac{\text{cond}(Q) - 1}{\text{cond}(Q)}$

Durch Einsetzen in die beiden Ungleichungen von Satz 10.2 iii) erhält man: $0 \leq f(x^{k+1}) - f(x^*) \leq \left(\frac{\text{cond}(Q) - 1}{\text{cond}(Q)}\right) (f(x^k) - f(x^*))$, $k \in \mathbb{N}_0$ und $\|x^k - x^*\| \leq c \cdot \left(\frac{\text{cond}(Q) - 1}{\text{cond}(Q)}\right)^k$, $k \in \mathbb{N}_0$.

Die Abschätzung beschreibt zwar nur ein worst-case-Verhalten, dies entspricht jedoch durchaus dem realen Verhalten: die Folge der Funktionswerte $(f(x^k))_k$ und der Iterierten $(x^k)_k$ konvergiert umso langsamer, je größer die Konditionszahl von Q ist.

Diese Konvergenzaussagen gelten nicht nur für quadratische Funktionen, sondern qualitativ auch für lokale Minimalpunkte x^* beliebiger $\mathcal{C}^2(\mathbb{R}^n)$ -Funktionen f , welche die hinreichende Optimalitätsbedingung 2. Ordnung aus Satz 1.15 erfüllen. In diesem kann f lokal um x^* durch ein quadratisches Taylorpolynom $g^k(x) := f(x^*) + \nabla f(x^*)^T (x - x^*) + \frac{1}{2}(x - x^*)^T \nabla^2 f(x^*) (x - x^*)$ mit positiv definit, symmetrischer Matrix $\nabla^2 f(x^*)$ angenähert werden. Langsame Konvergenz für das Gradientenverfahren ist dann für f zu erwarten, wenn die Kondition der Hesse-Matrix $\nabla^2 f(x^*)$ groß ist.

Anschaulich:



Ziel: Zuck-Urs der Iterierten.

Beispiel 9.5 Wenden Gradientenverfahren mit exakter Schrittweite an auf die quadratische Funktion $f(x) = \frac{1}{2}x^T Qx$ mit $Q := \begin{pmatrix} 2 & 0 \\ 0 & 10^3 \end{pmatrix}$ und $x \in \mathbb{R}^2$.
Problem (P) hat die Lösung $x^* = (0,0)$ mit Minimalwert $f(x^*) = 0$. Die Konditionszahl von Q ist $\text{cond}(Q) = 10^3$. Für die obige Konstante in den Abschätzungen erhält man $\frac{\text{cond}(Q) - 1}{\text{cond}(Q)} = 0,999$ was auf eine möglicherweise langsame Konvergenz hinweist. Die Abschätzung in x ist $p := -\nabla f(x) = -Qx$, woraus sich gemäß Beispiel 9.5 die Minimumschrittweite ergibt: $t_k = -\frac{\nabla f(x)^T p}{p^T Q p} = \frac{-\nabla f(x)^T \nabla f(x)}{-\nabla f(x)^T Q \nabla f(x)} = \frac{(x^T Q) (Qx)}{(x^T Q) Q (Qx)} = \frac{x^T Q^2 x}{x^T Q^3 x}$.
Es ist $Q^2 = \begin{pmatrix} 4 & 0 \\ 0 & 10^6 \end{pmatrix}$ und $Q^3 = \begin{pmatrix} 8 & 0 \\ 0 & 10^9 \end{pmatrix}$, also $t_k = \frac{x_1^2 + 10^6 x_2^2}{2(x_1^2 + 10^9 x_2^2)}$. Setze $t_k := t_k(x^k, p^k)$ und $x^k := (x_1^k, x_2^k)$ gilt dann: $x^{k+1} = x^k - t_k \cdot Q \cdot x^k = (I - t_k Q) x^k = \begin{pmatrix} 1 - t_k & 0 \\ 0 & 1 - 10^3 t_k \end{pmatrix} \cdot x^k$ mit $t_k := 2 t_k := \frac{x_1^2 + 10^6 x_2^2}{(x_1^2 + 10^9 x_2^2)}$.
Wählt man als Startpunkt $x^0 = (1, 10^{-2})^T$, so ist $t_0 = 2 t_0 = \frac{2}{1 + 10^3} = \frac{2}{1001} \approx 2 \cdot 10^{-3}$. Damit dann $(x_1^1, x_2^1) \approx (x_1^0, x_2^0)$. Damit ist $t_1 \approx t_0$ somit $(x_1^2, x_2^2) \approx (x_1^0, x_2^0)$. Der Fortschritt dürfte somit gering ausfallen.

Iteration:	k	x_1^k	x_2^k	$f(x_1^k, x_2^k)$	t_k
	0	1,000000	0,001000	1,001000	0,001998
	1	0,998002	-0,000998	0,997004	0,001998
	2	0,996008	0,000996	0,993024	0,001998

Startet man mit $x^0 = (0, 1)^T$ und $f(x^0) = 1000$, so ist $x_0 = 10^{-3}$ und somit $x^1 = (0, 0)^T = x^*$. Dito für $x^0 = (1, 0)^T$ und $f(x^0) = 1$, so ist $x_0 = 1$ und ebenso $x^1 = (0, 0)^T = x^*$.

Die Lösung wird mit einer Iteration des Verfahrens erreicht. Dies passiert beim Gradientenverfahren mit der Minimumsuchweite und einer quadratischen Funktion f mit positiv definiter Matrix Q immer dann, wenn x^0 so gewählt wurde, dass $x^0 = v - Q^{-1}c$, wobei v Eigenvektor zu einem Eigenwert $\lambda > 0$ von Q ist, d.h. $Qv = \lambda v$. Denn bei einer solchen Wahl von x^0 ist: $\nabla f(x^0) = Qx^0 + c = Q(v - Q^{-1}c) + c = Qv - \lambda v$ und $t_0 = \frac{\nabla f(x^0)^T \nabla f(x^0)}{\nabla f(x^0)^T Q \nabla f(x^0)} = \frac{\lambda^2 v^T v}{\lambda^2 v^T Q v} = \frac{1}{\lambda}$. Es folgt $x^1 = x^0 + t_0 (-\nabla f(x^0)) = x^0 - \frac{1}{\lambda} (\lambda v) = x^0 - v = (v - Q^{-1}c) - v = -Q^{-1}c = x^*$.

In der Praxis sind Gradientenverfahren am Anfang recht schnell, werden in der Nähe der Lösung langsam. Bis 1960 gab es aber keine guten Alternativen dazu.

11 Verfahren der konjugierten Richtungen / konjugierte Gradienten (CG-Verfahren)

CG-Verfahren (conjugate gradients) konvergieren in der Praxis oftmals schneller als Gradientenverfahren, aber langsamer als die globalisierten Newton-Verfahren bzw. Quasi-Newton-Verfahren (Kap. 12/13)

→ wir skippen das Kapitel aus Zeitgründen